DATA QUALITY / EVALUATION

多模态数据标注与质检

从标注规范到人工 vs 模型一致性评估

24 条文本 · 6 张图像 · 10 条语音 | Label Studio 1.23 | 2026.10

个人实训项目 · 所有指标来自实际标注与脚本复算

OVERVIEW

项目概览：三个模态，一条质检链路

TEXT

24

条文本任务

21 条正式集 · 3 路标注

IMAGE

6

张图像

5 张正式集 · 52 个框

AUDIO

10

条语音

CER 5.5% → 1.1%

流程

规范 v1.0 › 3 条试标 › 独立标注 › 100% 复核 › 分歧裁决 › 质检报告

产出：标注规范、任务数据、可复现脚本、IAA 指标、裁决表与报告。

LABEL SCHEMA

标注体系：四组字段，单选与多选分开

情感（单选）

正面 | 负面 | 中性 | 无法判断

方面（多选）

口味 | 配送 | 价格 | 服务 | 卫生 | 包装 | 无

质量标记（多选）

广告推广 | 含隐私 | 表述不清 | 模板/刷单 | 无

置信度（单选）

5 非常确定 | 4 | 3 | 2 | 1 纯猜测

设计原则

· 情感只选一个，避免“又正又负”

· 方面只标显式提及，不从情感反推

· 质量标记独立，广告/隐私不混入情感

· 置信度用于复核路由，不参与金标

完整规则见 docs/annotation-guideline.md（v1.1）。

RULES

判定规则：结论优先，证据加权

01 广告 / 无关 / 无意义

→ 无法判断

并打质量标记

02 有明确结论句

→ 按结论句

不要被前面的细节带偏

03 正负相当、态度平淡

→ 中性

没有明显褒贬

04 核心体验严重受损

→ 负面

否则判正面

边界样本	判定	理由
味道不错，就是有点咸	正面	轻微负向，总体肯定
呵呵，真是“神速”	负面	反讽按真实语义
还行。	中性	超短但可判断
地址 + 手机号	中性	无褒贬，另标隐私

易错点

混合情感、反讽、超短文本、隐私文本是本轮 5 条分歧的全部来源。

规则写在标注文档里；模型标注的 system prompt 也使用同一套规则。

WORKFLOW

流程：试标校准，正式独立，分歧裁决

01

试标

3 条边界样本
先暴露歧义

→

02

正式标注

3 个账号
overlap=3

→

03

复核

100% 输出分歧
逐条对照规范

→

04

裁决

写入 final_label
与 reason

控制点

独立性	3 个账号互不看结果；试标不计入正式统计
可追溯	每条标注记录账号、时间、置信度与理由
可复算	导出 JSON → 脚本重算 κ / α / F1 / CER

试标 3 条 → 校准会 → 规范 v1.1 → 正式 21 条；正式集全部 3 路标注。

METRICS

指标口径与判读

指标	回答的问题	本轮用途
一致率	同一批任务有多少比例标签相同	直观，但未校正随机一致
Cohen's κ	两个人之间，扣除随机一致后的一致性	人工 vs 各模型
Fleiss' κ	多人、任务完整时的一致性	三路整体
Krippendorff's α	允许缺失值的多标注员一致性	稳健性参考
F1 @ IoU≥0.5	图像框位置与类别是否匹配	图像框质量
CER	转写相对参考文本的字符错误率	语音修正前后

读法

κ / α > 0.80 较好
0.67–0.80 需讨论规范
< 0.67 应重写规范

阈值不是硬标准，
要结合任务难度和样本量。

本轮文本 κ=0.756、α=0.760，落在“需讨论规范”区间，不是“完美一致”。

RESULTS

本轮结果：文本中等一致，语音修正有效

文本三路一致性

84.1%

Fleiss κ 0.756 · α 0.760

图像框数

52

6 张图 · 5 张正式集 · 单人完成

语音 CER

1.1%

修正前 5.5% · 下降 80.2%

文本指标	值
全体一致任务	16 / 21
分歧任务	5 条，全部裁决
方面集合 Jaccard	0.696
语音完全正确	7 / 9

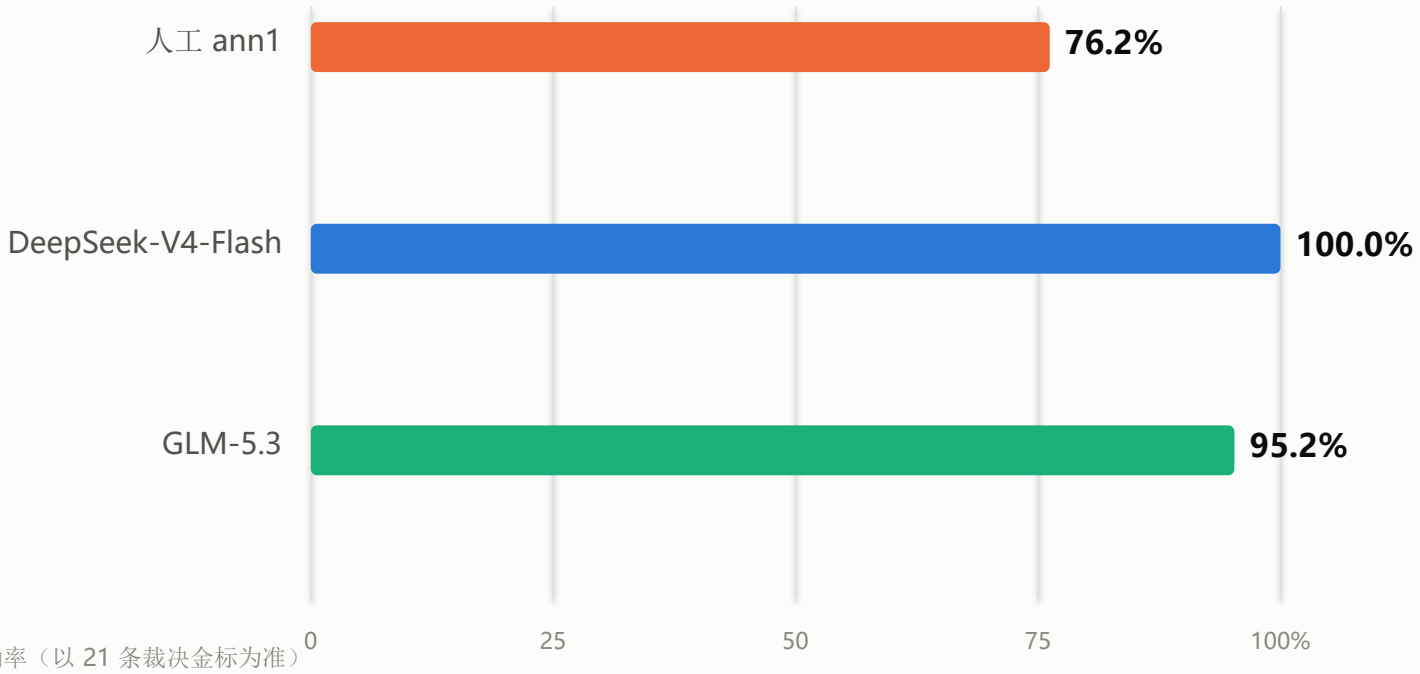
读数

文本一致性中等，主要风险在边界样本；
语音修正把 CER 从 5.5% 降到 1.1%；
图像只完成单人标注，暂不能算 IAA。

文本正式集 21 条、3 路标注共 63 条；图像为 6 张中的 5 张正式集。

EVALUATION

人工与模型标注对比



两两一致性

标注员对	κ
人工 vs DeepSeek	0.634
人工 vs GLM	0.701
DeepSeek vs GLM	0.929

模型之间高度一致，
与人只有中等一致。

差异主要来自规范执行条件，
不足以推断模型能力全面更强。

n=21；模型 prompt 含完整规范，人工只阅读文档；样本小，结论不外推。

ERROR ANALYSIS

错误分析：人工错误集中在边界样本

任务	文本（截断）	金标	人工	模型
T04	加微信领红包…	无法判断	中性	✓
T05	还行。	中性	正面	✓
T11	味道不错，但贵…	正面	中性	✓
T20	分量一般，味道一般…	中性	负面	✓
T22	地址 + 手机号	中性	正面	GLM ✗

三个发现

5 / 5 人工错误都落在边界样本

4 / 5 是“中性 / 无法判断”混淆

1 GLM 唯一错误：隐私文本判正面

规范文本本身不足以保证一致性；边界样本需要试标、校准和低置信度复核。模型可用于预标注，最终标签仍需人工裁决。

金标来源：16 条全体一致 + 5 条按规范裁决；错误列表来自 model_comparison.csv。

CALIBRATION

置信度校准：高置信度不等于高正确率

标注员	置信度 5	置信度 4	置信度 3	置信度 ≤2
人工 ann1	90.9% (11)	62.5% (8)	0% (1)	100% (1)
DeepSeek-V4-Flash	100% (12)	100% (9)	—	—
GLM-5.3	100% (10)	100% (9)	50% (2)	—

人工

置信度 5 仍有 1 条错；
置信度 4 只有 62.5%。
→ 不能只复核低置信度。

模型

置信度几乎全在 4–5，
区分度不足，不能直接当
“自动通过”信号。

准确率 = 与裁决金标一致；括号内为样本数。样本小，只作流程演示。

ACTIONS

改进：规范、流程与工具

规范

· 广告 / 隐私 / 超短 / 混合四类写成判定句

· “无”与其他标签互斥，避免多选污染

· 数字归一化写入评测口径

流程

· 试标从 3 条扩到 8–10 条

· 置信度 ≤3 的样本 100% 复核

· 每轮输出 per-label κ，低于 0.6 单独校准

工具

· 模型预标注，人工只审分歧

· 脚本自动生成分歧表与报告

· 记录 token / 延迟 / 成本

预期：边界样本错误从 5 条降到 ≤2 条；复核量集中到低置信度，而不是全量重标。

下一轮可用同一批任务复标，对比 κ 与人工准确率是否提升。

CONCLUSION

结论与局限

结论

1 规范可执行，但边界样本是主要风险：人工 5/21 偏离规范。

2 模型间一致性高（κ 0.929），与人只有 0.63–0.70；可做预标注，不替代人工。

3 语音修正有效（CER −80.2%）；图像需第二人复标才能算 IAA。

局限

· 样本量小：正式集 21 条，κ 置信区间宽。

· 条件不对等：模型 prompt 含完整规范。

· 人工只有 1 人，图像无第二人复标。

· 语音为 TTS 合成 + 受控错误。

复现：start_label_studio.bat + start_data_server.bat → scripts/analyze.py → scripts/compare_models.py

仓库：configs/ · data/ · docs/ · scripts/ · reports/